Guía del paquete de reproducibilidad (para Mónica)

Esta guía explica, en palabras simples, qué hay en la carpeta `reproducibility/`, para qué sirve cada programa, cómo se ejecuta y cómo subirlo a Zenodo. El manual oficial, en inglés, para editores y revisores es `reproducibility/README.md`; esta guía es para que tú puedas entenderlo y defenderlo.

---

1. Qué es el paquete

Es una carpeta autocontenida con todo lo que respalda el paper:

Carpeta	Qué contiene	En palabras simples
`analysis/`	los programas del método y de cada análisis (Python)	lo que "calcula"
`results/`	los resultados de esos cálculos, un archivo por problema (unos 40 MB)	los números del paper
`figures_tables/`	los programas que hacen cada figura, tabla y nota del suplemento	lo que "dibuja"
`lean_proofs/`	las demostraciones en Lean 4 (32 módulos, 309 teoremas y lemas, 28 modelos, y los testigos de no vacuidad)	lo que "demuestra"
`lean_translation/`	el traductor SBML → Lean y la comprobación de la traducción	el puente entre modelos y Lean
`scripts/`	descarga del benchmark y comparación de resultados	utilidades

No incluye los problemas PEtab (se descargan con `scripts/get_benchmark.sh`). El paper ya no analiza datos de personas.

---

2. Qué hace cada programa (en orden de uso)

Programa (`analysis/`)	Qué hace	Produce
`config.py`	guarda todos los umbrales del paper (δ = 1 %, τ_R = 0,89, κ/VIF ≤ 10, τ_e = 0,436, 15 escenarios, semilla 42)	—
`petab_problem.py`	simula las **salidas medidas** de un problema PEtab: y_i = h(g_i(x(t_i), θ))/σ_i	—
`simulator_check.py`	compara nuestra simulación con la del benchmark	Tabla S9
`selection.py`	**el método**: sensibilidad J, etapa 1 (energía), etapa 2 (efecto finito), κ/VIF, admisibilidad con e_fit, poda	Fig. 2, Tabla 1, Tabla S1
`selection.py --variant …`	lo mismo cambiando un ajuste (δ, tolerancias, ±1 %/±10 %, τ_R, κ/VIF, τ_e)	Fig. 5, Tabla S14
`external_validation.py`	ajusta con unos experimentos y predice los otros (datos reales y sintéticos)	Fig. 3, Fig. S1, Tabla S12
`synthetic_seeds.py`	experimento sintético con 20 semillas; con `SINT_SOLO_SENAL=1` calcula solo la señal $y(\theta^*)-y(\theta_0)$ en σ, y con `SINT_AMPLITUD=0.05/0.50` repite el experimento con otras amplitudes (punto C3)	Fig. 3b; tabla y figura de señal y amplitudes

Programa (`analysis/`)	Qué hace	Produce
`robustness.py`	mide el error a ±1…50 % con las mismas 15 direcciones; patrones A–D	Fig. 5, Tablas S10–S11, Fig. S2
`robustness.py` con `ROBUST_INDEP=1`	lo mismo con direcciones **nuevas** en cada tamaño (punto B5 de la auditoría)	tabla y figura de direcciones independientes (nota de robustez)
`absolute_error.py`	expresa el error que deja el reducido en unidades del ruido σ (punto C1)	tabla del error en σ (nota de ajustes)
`single_parameter.py`	prueba si un solo parámetro bastaría (justifica k_min = 2)	Tabla S13
`crauste_blowup.py`	muestra por qué Crauste no tiene reducción local	texto de Resultados
`timing.py`	mide el tiempo de una simulación	Tabla S15

Programa (`lean_translation/`)	Qué hace
`sbml_to_lean.py`	traduce cada modelo SBML a un archivo Lean con números racionales exactos
`verify_translation.py`	comprueba, sin usar el traductor, que el archivo Lean es el mismo modelo que el SBML (diferencia ~10^{-12})
`mutation_control.py`	control: si se cambia un número del archivo Lean en 1 %, la comprobación lo detecta (~10^{-2})

`figures_tables/build_all.py` ejecuta todos los generadores de figuras, tablas y notas; entre ellos `make_review_notes.py`, que produce las tablas y figuras de los análisis adicionales (direcciones independientes, señal y amplitudes, error en σ y variantes de ajustes de Lang y Raimundez), y `make_timing_notes.py`, que reúne el tiempo de cómputo de cada análisis en cada problema (campo `segundos` de los resultados) y produce las tablas de la nota "Computing time of the analyses" del suplemento; su objetivo es mostrar que seleccionar y verificar un subconjunto es asequible (minutos en casi todos los problemas, mucho menos que la verosimilitud perfilada del modelo completo, que no fue viable en los problemas grandes). `figures_tables/main_text_numbers.py` recalcula las cifras que cita el texto principal (admisibles, identificabilidad, validación, comparación de criterios, robustez) para comprobarlas tras cualquier cambio.

2b. Programas añadidos en la segunda auditoría (versión 1.5)

Programa	Qué hace	Por qué	Produce
`selection.py` con `REPRO_FIXED_SCEN=1`	repite la selección con un conjunto fijo de escenarios y registra la monotonía	antes un escenario que fallaba se descartaba y cada subconjunto podía evaluarse con escenarios distintos; el Teorema 2 suponía monotonía	`results/selection_fixedscen/` (ningún subconjunto cambió; 0 violaciones en 660 pares)
`selection.py` con `REPRO_OUTPUTS=train`	repite tu selección viendo solo las salidas de entrenamiento	los demás criterios elegían con entrenamiento y el tuyo con todas las salidas	`results/selection_train_fixedscen/`
`qr_selection.py` con `QR_VARIANT=gks`	QR pivotado estándar (Golub–Klema–Stewart)	el QR anterior no era el algoritmo de la literatura	`results/qr_selection_gks/`

Programa	Qué hace	Por qué	Produce
`criteria_tests.py`	admisibilidad de todos los criterios, de k = 0 y de 20 subconjuntos al azar; con `SINT_FAMILIA=loguniforme` o `dispersa`, otras familias de verdades sintéticas	controles nulos y una prueba sintética que no use la misma familia que tu método	`results/criteria_tests_*`
`efit_nonlinear.py`	re-estimación no lineal de los 6 problemas de primer orden	su admisibilidad se había decidido solo con la aproximación lineal	`results/efit_nonlinear/` (los 6 se confirman)
`conditioning_check.py`	κ y VIF con columnas centradas y sin centrar	el código y Lean usan normalizaciones distintas	`results/conditioning_check.json`
`identifiability_profiles.py` con `ID_DENSE=1` o `ID_SUBSETS=…`	perfiles con 20 puntos por lado, o de otros subconjuntos	ver si la clasificación depende de la resolución, y perfilar los subconjuntos de entrenamiento	`results/identifiability/profiles_dense/`, `profiles_selection_train_fixedscen/`
`identifiability_box.py`	comprueba las hipótesis de los teoremas de Lean de identificabilidad en toda la región alrededor del óptimo (factor 10, 5, 3, 2 y 1,5)	antes se comprobaban solo sobre el perfil	`results/identifiability/box/`, `results/identifiability/audit2/`
`scripts/run_second_review.sh`, `scripts/run_identifiability_second_review.sh`	lanzan todo lo anterior en un servidor de muchos núcleos	—	—
`figures_tables/audit2_stats.py`, `audit2_tables.py`	estadísticas (McNemar, bootstrap, Holm), Tabla 2 y tablas nuevas del suplemento	—	Tabla 2, Fig. 4, tablas S nuevas
`lean_proofs/NonVacuity.lean`	ejemplos verificados que muestran que las hipótesis de cada teorema central se pueden cumplir	descartar teoremas vacíos	—
`lean_proofs/DEFINITIONS_AUDIT.md`	compara cada definición de Lean con el paper y el código	descartar que el enunciado no diga lo que el paper afirma	—

2c. Pruebas añadidas el 17 de octubre de 2026 (versión 1.6)

Programa	Qué hace	Por qué	Produce	Tiempo
`scripts/run_identifiability_other_criteria.sh` (usa `prepare_criteria_subsets.py`, `identifiability_profiles.py` con `ID_SUBSETS`, `compare_identifiability_criteria.py`)	calcula el perfil de verosimilitud de los parámetros que eligieron Brun, Morris, QR estándar y el perfil de verosimilitud, con el mismo procedimiento que tus subconjuntos; los cuatro criterios corren a la vez	saber si sus parámetros son tan identificables como los tuyos y si alguno logra parámetros identificables **y** suficientes a la vez	`results/subsets_*/`, `results/identifiability/profiles_subsets_*/`, `criteria_identifiability.json`; columna *Identifiable* de la Tabla 2 y nota del suplemento	~2 h en 128 núcleos; 41 h de procesador

Programa	Qué hace	Por qué	Produce	Tiempo
`scripts/run_test_kmin.sh` (usa `prepare_single_subsets.py`, `robustness.py` con `ROBUST_SUBSETS`, `criteria_tests.py` con `CT_METODOS=single`, `identifiability_profiles.py`, `compare_single_vs_pair.py`; luego `kmin_times.py`)	en los 15 problemas donde un solo parámetro ya basta, pasa el mejor parámetro solo por las mismas pruebas que tu par: robustez de ±1 % a ±50 %, admisibilidad a ±20 %, predicción sintética e identificabilidad	justificar con datos el mínimo de dos parámetros (k_min = 2)	`results/subsets_single/`, `robustness*_subsets_single/`, `kmin_comparison.json`, `kmin_times.json`; nota del suplemento y limitación (iii)	27 min en 88 núcleos; 5,7 h de procesador
`figures_tables/identif_criteria_tables.py`, `kmin_tables.py`	generan las tablas del suplemento de estas dos pruebas	—	tablas S nuevas	segundos
`scripts/setup_server.sh`	prepara un servidor Linux nuevo (clona el repositorio, instala Python y baja los modelos)	facilitar repetir las pruebas en un servidor alquilado	—	~5 min

Resultados. Identificabilidad: tus parámetros, los de Brun y los del perfil son igual de identificables (85–86 %); Morris (80 %) y QR (76 %) menos. Identificables **y** suficientes: tú 21 de 27 problemas, Brun 18, Morris 14, perfil 14, QR 7. Mínimo de dos: un parámetro solo es igual de identificable y predice igual, pero falla en más escenarios (pasan 88 % frente a 94 %) y su error crece más con cambios grandes (18,7 % frente a 10,9 % a ±50 %): el segundo parámetro es un margen de seguridad.

---

3. Cómo ejecutarlo en tu computadora

Necesitas Python 3.11. En una terminal, dentro de la carpeta `reproducibility/`:

```
python -m venv .venv
.venv\Scripts\activate          (en Windows; en Mac/Linux: source .venv/bin/activate)
pip install -r requirements.txt
```

Nivel A (unos dos minutos): rehacer figuras y tablas desde los resultados guardados

```
cd figures_tables
python build_all.py
```

Aparecen en `figures_tables/output/`. Para Fig. 6 y las copias EPS/TIFF hacen falta `pdflatex` y poppler (`pdftops`, `pdftoppm`).

Nivel B (20 minutos con muchos núcleos, 1–2 horas en un portátil): compilar Lean

Instalar elan (https://github.com/leanprover/elan) y luego, dentro de `lean_proofs/`: `./verify.sh` (en Windows, desde Git Bash o WSL).

Nivel C (1–2 días en total): recalcular desde cero

```
bash scripts/get_benchmark.sh
set REPRO_RESULTS=%CD%\results_rerun      (Windows cmd; en PowerShell:
$env:REPRO_RESULTS="$PWD\results_rerun")
cd analysis
python selection.py Boehm_JProteomeRes2014
cd ..
python scripts/compare_results.py results_rerun/selection results/selection
```

Puedes recalcular un solo problema (como en el ejemplo) o todos (sin nombres). Los pasos y tiempos están en la tabla del README.

Análisis de la segunda auditoría (en un servidor Linux de muchos núcleos):

```
bash scripts/get_benchmark.sh
NCORES=88 nohup bash scripts/run_second_review.sh > second_review.log 2>&1 &          (unas 6 h con 88
núcleos)
NPROC=30 nohup bash scripts/run_identifiability_second_review.sh > identif.log 2>&1 &  (unas 5 h)
cd analysis && python conditioning_check.py
```

Al terminar, `cd figures_tables && python build_all.py` rehace la Tabla 2, la Fig. 4 y las tablas nuevas.

---

4. Qué comprobé antes de entregártelo

- **Ejemplo SCT retirado (16-10-2026).** El estudio original de los pasos no pasó por un comité de ética y *Scientific Reports* exige nombrar al comité que aprobó cualquier investigación con personas. Por eso el paper ya no analiza esos datos: solo cita tu artículo previo como motivación. Se quitaron la subsección de Resultados, la de Methods, la nota del suplemento, su tabla y la Fig. S3, y del paquete los programas `sct_*.py`, `make_sct_note.py` y `results/sct/`. La declaración de ética ahora es «Not applicable». Tu archivo de datos sigue en tu OneDrive; la copia CSV está en `reproducibility/data/sct/` (excluida de git) y puedes borrarla si quieres.
- **Código equivalente.** Los programas del paquete son versiones ordenadas (en inglés) de los que usamos (`certificados/`). Comprobé automáticamente que la lógica es la misma, comparando la estructura del código función por función, y además volví a ejecutarlos y comparé los resultados con los guardados (ver la sección 6).
- **Traducción a Lean.** Al volver a ejecutar el traductor, los 28 archivos de modelos salen **idénticos** a los que se compilaron.
- **Figuras y tablas.** En un entorno de Python nuevo, instalado solo con `requirements.txt`, el nivel A regenera todo en unos 20 segundos, y las tablas, las figuras y las notas coinciden con las del paper.
- **Benchmark.** `get_benchmark.sh` descarga exactamente los mismos archivos que usamos (commit fcbddf1).
- **Segunda auditoría (16-10-2026).** El nivel A regenera en Windows todas las tablas del paper y del suplemento **idénticas** a las enviadas . Algunas notas del suplemento se retocaron a mano después de generarlas (redacción y números de figura), así que su texto regenerado puede variar en la redacción, no en las cifras.

- **Lean (16-10-2026).** Compilación desde cero en una copia limpia: 309 de 309 teoremas y 28 de 28 modelos solo con los axiomas estándar; `lean4checker` aceptó todos los módulos; un control negativo con `sorry` fue detectado. Se corrigieron dos errores de `verify.sh` (no comprobaba de verdad los modelos y fallaba al ejecutarlo dos veces).

- **Un error mío que corregí al armar el paquete.** Los certificados nuevos de identificabilidad se guardaban en la misma carpeta que leen las tablas del paper y las alteraban al regenerarlas; ahora están en `results/identifiability/audit2/` y las tablas regeneradas coinciden con las del paper.

---

5. Correcciones que salieron al armar el paquete

Al rehacer todo con cuidado aparecieron cuatro cosas que corregí en el paper:

1. **Prueba de un solo parámetro.** La validación externa del mejor parámetro único no reajustaba los parámetros de calibración (escalas, offsets), mientras que la del subconjunto S sí. Lo recalculé de forma justa (con la calibración, igual que S) y actualicé la Tabla S13 y la frase del paper.
2. **Crauste.** El paper decía que con ρ_E −1 % los efectores pasan de 5×10^2 a 5×10^5 en cuatro días, pero eso también ocurre con los parámetros publicados. Lo correcto: con los parámetros publicados los efectores llegan a $\sim10^6$ cerca del día 10 y luego bajan; con un cambio del 1 % siguen creciendo y la solución se rompe entre los días 8,8 y 9,9. Ocurre en 9 de las 24 perturbaciones (antes decía "8–9") y en 7 de 15 escenarios, con cualquier tolerancia.
3. **Robustez: una sola corrida.** Había dos corridas de robustez (la segunda guarda cada escenario). Ahora todo sale de la segunda. Solo cambia Chen, que en Methods pasa de "entre 7 y 13 escenarios" a "entre 8 y 13"; los patrones y todas las demás cifras son iguales.
4. **Rutas.** El paper y el suplemento citaban programas de `certificados/`; ahora citan el paquete.

---

6. Cómo subirlo a Zenodo (paso a paso)

1. Entra a https://zenodo.org con tu cuenta (puedes usar ORCID o GitHub).
2. **New upload**.
3. Arrastra el archivo `Reproducibility_package_v1.6.0_2026-10-17.zip` (está en tu carpeta de Descargas y en `zenodo/` del repositorio). Como el registro ya existe (DOI 10.5281/zenodo.23338175), **no crees uno nuevo**: entra al registro y pulsa **New version**; Zenodo le da un DOI nuevo a la versión y mantiene el historial.
4. Pulsa **Reserve DOI** (o "Get a DOI now"): Zenodo te muestra el DOI, algo como `10.5281/zenodo.1234567`.
5. Completa los datos:
   - *Resource type*: Software.
   - *Title*: "Reproducibility package: Re-estimation-verified selection of small parameter subsets for systems biology models".
   - *Creators*: los cuatro autores, con afiliación ESPOL (y ORCID si los tienen).
   - *Description*: puedes copiar el primer párrafo del README.
   - *License*: MIT.
   - *Version*: 1.6.0. El título debe ser **idéntico** al del paper (punto N9 de la auditoría).
6. **Antes de publicar**, pon el DOI en el paper. En `main.tex` y `supplementary.tex` (arriba del todo) reemplaza `10.5281/zenodo.XXXXXXX` por tu DOI en la línea `\newcommand{\zenododoi}{...}`; con eso se actualizan todas las menciones. Compila de nuevo.

7. Publica en Zenodo. Si después hay cambios (por ejemplo tras la revisión), se sube una **nueva versión** del mismo registro y Zenodo le da otro DOI, manteniendo el historial.

Si prefieres no publicar todavía, Zenodo permite reservar el DOI y dejar el registro en borrador.

---

7. Si un revisor pregunta…

Pregunta	Respuesta y dónde está
¿Cómo reproduzco una cifra?	README, tabla "Where each result comes from": cifra → programa → archivo de resultados
¿Qué significa un campo del JSON?	`DATA_DICTIONARY.md`
¿Son deterministas los resultados?	Sí: semillas fijas. Solo Chen puede variar levemente (algunas simulaciones fallan al integrar)
¿Por qué hay nombres en español en los resultados?	Son los nombres originales de los programas; el diccionario los traduce
¿El archivo Lean es de verdad el modelo del benchmark?	`verify_translation.py` (diferencia ~10^{-12}) y el control del 1 %
¿Por qué no está el modelo completo de Chen y Raimundez en el sintético?	Tienen más de 100 parámetros libres; con datos reales sí se reajusta (validación anidada)
¿Por qué Lang no es admisible?	La búsqueda voraz no llega a un par admisible con los ajustes por defecto, aunque existen (nota *Random scenarios and large problems*, tabla de variantes de Lang)
¿Cómo se tratan los parámetros negativos o nulos en los escenarios?	Perturbación multiplicativa sin recorte: conservan el signo; los nulos se representan por 10^{-12} y nunca se eligen (misma nota)
¿Se obtiene lo mismo en otra máquina?	Sí: la selección de Lang y Raimundez coincidió con libRoadRunner 2.9.2 y 2.10.0 (e_fit iguales hasta 10^{-8})
¿Tu método vio los datos de prueba al elegir?	Sí en la selección principal; por eso se repitió con solo entrenamiento (`selection_train_fixedscen/`): rinde como Brun y mejor que QR y perfil
¿Pasar la prueba de admisibilidad tiene mérito?	Controles nulos: al azar ~16/28, solo calibración 9/28, frente a 28/28 (`criteria_tests_fixedscen/`)
¿Las demostraciones de Lean son vacías?	No: `NonVacuity.lean` da un ejemplo verificado de cada teorema central; `DEFINITIONS_AUDIT.md` compara definiciones
¿Cómo sé que Lean no dejó pasar un hueco?	`verify.sh` informa los axiomas de los 309 teoremas y 28 modelos, `lean4checker` los revisa otra vez, y un `sorry` de prueba se detecta (`BUILD_LOG.md`)